

AI Gateways

Mais segurança e maior governança em suas soluções de Inteligência Artificial

Renato Groffe

Microsoft MVP, Docker Captain, Grafana Champion

linkedin.com/in/renatogroffe

renatogroffe.medium.com

Milton Camara Gomes

Microsoft MVP, MTAC


linkedin.com/in/miltoncamara

youtube.com/azurenapratica




Renato Groffe

- Microsoft Most Valuable Professional (MVP)
- Docker Captain
- Grafana Champion
- APISEC U Ambassador
- Multi-Plataform Technical Audience Contributor (MTAC)
- Arquiteto de Soluções/Software
- +20 anos de experiência na área de Tecnologia
- Community Leader, Autor Técnico e Palestrante



Milton Câmara

- Microsoft Most Valuable Professional (MVP)
- Head de Engenharia – Robbu Tecnologia
- Arquiteto de Soluções/Software
- +20 anos de experiência na área de Tecnologia
- Community Leader, Autor Técnico e Palestrante



Participe de nossas iniciativas gratuitas

- Eventos online e gratuitos

<https://www.meetup.com/dotnet-Sao-Paulo/>



29/08 - EVENTO GRATUITO - SÃO PAULO-SP

SÁBADO, A PARTIR 08:30 DA MANHÃ

CLOUD WEEKEND 2026

NUVEM, CONTAINERS, AZURE,
INTELIGÊNCIA ARTIFICIAL...

LOCAL: ESCOLA SENAI SUÍÇO-BRASILEIRA - SANTO AMARO



Conteúdos desta apresentação



Deixem um star 🌟
apoioando

github.com/renatogroffe/ai-gateways_ia-sem-desperdicio-2026-08



Agenda

- AI Gateways: visão geral, possibilidades e alternativas
- Exemplos práticos



O que é um AI Gateway?

- Ponto central de acesso aos modelos de IA
- Centraliza chamadas para diferentes provedores
- Abstrai detalhes dos modelos e APIs
- Aplica políticas antes das requisições
- Facilita o gerenciamento de aplicações de IA



Por que utilizar um AI Gateway?

- **Segurança:** controle de acesso e proteção das APIs
- **Governança:** políticas centralizadas para uso de IA
- **Observabilidade:** métricas, logs e rastreamento
- **Custos:** controle e acompanhamento do consumo
- **Flexibilidade:** troca de modelos sem alterar aplicações



Segurança para aplicações de IA

- Autenticação e autorização centralizadas
- Controle de acesso por aplicação ou usuário
- Rate limiting e proteção contra abusos
- Gerenciamento seguro de credenciais
- Filtros para requisições e respostas



Governança e Controle com AI Gateways

- Políticas de uso dos modelos
- Limites de tokens e requisições
- Controle de modelos e provedores permitidos
- Auditoria e rastreabilidade das chamadas
- Chargeback e acompanhamento de custos (FinOps)



Iniciativas OWASP voltadas à área de IA


- OWASP Top 10 for LLM Applications 2026
- OWASP Top 10 for Agentic Applications for 2026
- OWASP MCP Top 10



AI Gateways: algumas alternativas

- APISIX
- Azure API Management (APIM)
- Azure AI Gateway
- Kong
- LiteLLM
-





Apache APISIX | AI Gateway

Security



Token Rate Limiting



Prompt Guard



Content Moderation



Logging & Auditing



Prompt Engineering



RAG-Enhanced Prompt



Prompt Decorator



Prompt Template



Observability



Prompt & LLM logs



LLM Latency



Token Usage



Analysis



Reliability



Multi-LLM Load Balancing



LLM Weight and Priority



Retry and Fallback



Caching

LLMs



OpenAI



DeepSeek



Grok



Google Gemini



Claude



Mistral AI



Qwen



Amazon Bedrock



More

Vector Database



PostgreSQL



Redis



Elastic



More

Content Moderation



aws



Azure

Conteúdos desta apresentação



Deixem um star 🌟
apoioando

github.com/renatogroffe/ai-gateways_ia-sem-desperdicio-2026-08



EXEMPLOS PRÁTICOS

OBRIGADO!

